2023 高雄市第 63 屆中小學科學展覽會
作品說明書

科別：數學科

組別：高級中等學校組

作品名稱：氧經續神

關鍵詞：演算法、迴歸分析、條件機率

編號：30101

摘要

臭氧能透過吸收紫外線保護地球上的生物，在自然界中是不可或缺之存，但人類工業科技之進步，也進一步影響到臭氧層，因此本研究想探討影響臭氧之各種變因並利用各種不同數學模型預測臭氧濃度，進而了解各變因對臭氧之數學關係。

本研究採用全高雄市 2021 年 10 月到 2022 年 2 月之天氣資料，並使用 AMB_TEMP 、$NMHC$ 、 NO_2 、 NO_x 、 RH、 THC 共六種因子搭配線性迴歸、多項式迴歸、多元線性迴歸、決策樹、類神經網路共五種數學模型進行臭氧濃度預測。線性迴歸屬於線性函數，其所預測之最高值為 38.91% ，影響因子為 NO_x；多項式迴歸屬於多項式函數，其所預測之最高值為 37.59% ，影響因子為 NO_x；多元線性迴歸屬於線性迴歸的擴展形式，在透過反向淘汰法得出預測最高值為 65.89% ；決策樹是基於條件機率之模型，屬於非線性函數，其所預測之最高值為 64.15 %；類神經網路是模擬人腦神經的數學模型，結合線性函數及非線性函數，其所預測之最高值為 69.15%。

目錄

壹、前言 1

一、研究動機 1

二、研究目的 1

（一）比較秋冬兩季臭氧濃度與其他變因的相關係數 1

（二）探討各預測模型之數學意義 1

（三）比較不同建立模型方式的準確度 1

三、文獻探討 1

（一）名詞定義 1

（二）臭氧成因 2

（三）皮爾森相關係數 4

貳、研究設備及器材 4

一、繪圖軟體與編輯工具 4

二、中央氣象局觀測資料查詢系統 4

三、行政院環保署空氣品質資訊網 4

參、研究過程與方法 5

一、臭氧及影響因子 5

（一）數據蒐集 5

（二）數據分析 5

（三）數據篩選 5

二、模型建立方法 6

（一）線性迴歸 6

（二）多項式迴歸 6
（三）多元線性迴歸 6
（四）多元線性迴歸反向淘汰法 7
（五）決策樹 7
（六）類神經網路 7
肆、研究結果 8
一、比較秋冬兩季臭氧濃度與其他變因的相關係數 8
二、觀察各預測模型之預測結果及其準確度 10
（一）線性迴歸 10
（二）多項式迴歸 12
（三）多元線性迴歸 15
（四）多元線性迴歸反向淘汰法 16
（五）決策樹 16
（六）類神經網路 17
伍、討論 18
一、探討各預測模型之數學意義 18
（一）線性迴歸 18
（二）多項式迴歸 19
（三）多元線性迴歸 19
（四）決策樹 20
（五）類神經網路 20
二、比較不同建立模型方式的準確度以及其可行性 22

（一）線性迴歸 22
（二）多項式迴歸 22
（三）多元線性迴歸 23
（四）決策樹 23
（五）類神經網路 23
三、比較不同研究之結果 25
陸、研究結論 26
一、比較秋冬兩季臭氧濃度與其他變因的相關係數 26
二、探討各預測模型之數學意義 26
（一）線性迴歸 26
（二）多項式迴歸 26
（三）多元線性迴歸 26
（四）決策樹 26
（五）類神經網路 27
三、比較不同建立模型方式的準確度 27
四、未來展望 27
柒、參考資料 28
一、網站資料 28
二、文獻資料 28

壹、前言

一、研究動機

臭氧的功能是一體兩面的，在好的方面，臭氧層吸收從太陽射出的紫外線，從而保護地球上的生物；另一方面，若臭氧達到一定濃度，則會對於呼吸道、眼睛等部位產生影響。因為現在 AI 極速發展，大數據分析為數學應用的新熱點，所以本研究不自限於傳統統計的線性迴歸，而是納入資訊輔助與機器學習理論，期盼以真實的資料，建構並比較不同數學理論的空污模型來預測臭氧濃度。想藉由一些數學模型的建立來預測臭氧濃度，於是本研究先比較影響臭氧濃度的變因，再建立各種預測模型，最後比較不同模型的準確度。

二、研究目的

基於上述研究動機，本研究之目的如下：

（一）比較秋冬兩季臭氧濃度與其他變因的相關係數

（二）探討各預測模型之數學意義

（三）比較不同建立模型方式的準確度

三、文獻探討

（一）名詞定義

本研究使用行政院環保署空氣品質資訊網內之資料，以下為使用資料之名詞中英文對照表。

表 1-1 觀測資料之中英文對照表

英文	AMB_TEMP	CH_4	CO	$NMHC$	NO_2	NO_x	O_3	RH	THC
中文	溫度	甲烷	一氧化碳	非甲烷碳氫化合物	二氧化氮	氮氧化物	臭氧	濕度	四氫大麻酚

（行政院環保署，2010）

（二）臭氧成因

在冬夏季節轉換之際，整體環境風場主要為偏東風，西半部位於背風面，竹苗至高屏空品區整體風速微弱，污染物容易在大氣中累積，不利擴散，空氣品質普遍較差。此外，當風遇到地形繞流後，容易在臺灣海峽上產生背風渦旋，並將原已擴散至海面上的污染物又再度帶往陸地，易使局部地區空氣污染物濃度上升。在這季節交替之際，也因天氣穩定，白天雲量偏少、日照時數偏多，有利於光化反應產生，可使空氣中的臭氧濃度升高，特別於午後臭氧 8 小時濃度通常較高。

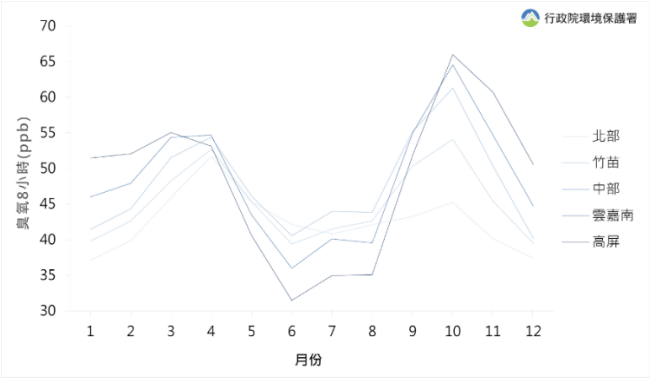

圖 1-1 臭氧在一年中的濃度變化

（行政院環保署，2019）

由 O_3 、 $NMHC$ 、 NO_x 及 CO 逐時濃度作變化趨勢比較，可明顯看出當臭氧濃度升高時 $NMHC$ 、 NO_x 及 CO 濃度下降；相反的，臭氧濃度下降時， $NMHC$ 、 NO_x 及 CO 濃度有顯著升高的趨勢。除了上述所言之因素，降雨亦是不利於臭氧的生成。

（蔡詠安，2002）

光解反應為製造臭氧的方法之一，其中重要因子為 NO_2 ，反應如下：

$$NO_2 + hv \rightarrow NO + O(^3P)$$

$$NO_2 + hv \rightarrow NO + O(^1D)$$

$$O(^3P) + O_2 + M \rightarrow O_3 + M$$

$$O_3 + NO \rightarrow NO_2 + O_2$$

h 為普朗克常數、v 為光波的頻率、M 為能量吸收體 （柳中明等，1991）

光化學煙霧與臭氧的前驅物（precursors）包括揮發性有機碳化物 （$VOCs$） 及氮氧化物（NO_x），而一般常以非甲烷碳氫化合物（$NMHC$）等同於 VOC。由於 $VOCs$ 的來源非常複雜，且不同的物種（species）參與光化學反應的活性不同，故其排放來源與排放數量的掌握十分困難，影響光化反應的碳氫化合物主要為反應性有機氣體的光化學反應來完成。在式中所產生的氧原子會和大氣中的碳氫化合物反應（碳氫化合物以 HC 作代表），可產生一系列的反應性自由基。如下式所示：

$$HC + OH^{\cdot} \longrightarrow R^{\cdot} + H_2O$$

$$O_3 + HC \longrightarrow RCHO + RO^{\cdot} + HCO^{\cdot}$$

$$R^{\cdot} + O_2 \longrightarrow ROO^{\cdot}$$

$$ROO^{\cdot} + NO \longrightarrow NO_2 + RO$$

HC 為碳氫化合物、 $R^{\cdot}$ 為自由基

當大氣中存在大量 CO 時，則 NO 轉化為 NO_2 的機制如下所示：

$$OH^{\cdot} + CO \longrightarrow CO_2 + H^{\cdot}$$

$$H^{\cdot} + O_2 + M \longrightarrow HO_2^{\cdot} + M$$

$$HO_2^{\cdot} + NO \longrightarrow OH^{\cdot} + NO_2$$

（蔡詠安，2002）

（三）皮爾森相關係數

本研究採用相關係數作為變因篩選之基準，而相關係數（Coefficient of Correlation）為統計學中常用來反映變數間密切程度之指標，常以字母 r 表示。設有兩組變數 x_i 與 y_i ，皆有 n 項，則兩組變數之密切程度相關係數

$$r = \frac{\sum_{i=1}^{n}(x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^{n}(x_i - \bar{x})^2}\sqrt{\sum_{i=1}^{n}(y_i - \bar{y})^2}}$$

當 $0 \leq |r| \leq 0.25$ ，表示不存在相關性；當 $0.25 \leq |r| \leq 0.5$ ，表示低度相關；當 $0.5 \leq |r| \leq 0.75$ ，表示中度相關；當 $0.75 \leq |r| \leq 1$ ，表示高度相關。（Laerd Statistics，2021）

貳、研究設備及器材

一、繪圖軟體與編輯工具

（一）Microsoft Word：編輯文件

（二）Google Sheets：繪製圖表與計算數據

（三）Colaboratory Python：用來計算各種演算法預測臭氧濃度

二、中央氣象局觀測資料查詢系統

將全高雄 2 個測站的天氣資料與臭氧濃度繪製成圖表。

三、行政院環保署空氣品質資訊網

研究者的空氣品質資料取自此網站中各測站資料，因為 2023 年的資料只有兩個月，故以 2022 年的資料作為主要參考依據。

參、研究過程與方法

圖 2-1 研究流程圖

一、臭氧及影響因子

蔡詠安（2002）提出影響臭氧主要因子 $NMHC$、NO_x、CO、$VOCs$、NO_2 及 RH 皆為影響臭氧濃度之重要因素，但因時空背景的不同，前人的研究數據或許會與空氣品質的現狀產生落差，為求數據之嚴謹適切，本研究將重新分析數據以確定影響臭氧之因素及影響程度。

（一）數據蒐集

利用行政院環保署空氣品質資訊網中數據進行分析，本研究採用高雄地區包括：大寮、左營、楠梓、仁武、鳳山等共十二個觀測站之空氣資料，所選取之空氣資料包括：

AMB_TEMP、CH_4、CO、$NMHC$、NO_2、NO_x、O_3、RH 與 THC 共九組數據。蔡詠安（2002）提出行政院環保署（2019）所釋出的資料，以 10 月之臭氧濃度為一年中最高，為了保持風向一致，時間上本研究決定選擇 2021 年 10 月 01 日 至 2022 年 2 月 28 日。

（二）數據分析

為驗證文獻中所提及影響臭氧之因子符合此次實驗之時空背景，本次研究藉由分析 AMB_TEMP、CH_4、CO 等八個數據對臭氧之相關係數作為篩選依據。

（三）數據篩選

過多因子的納入，雖能增加準確度，卻會影響後續應用性，故本研究依據皮爾森相關係數，採取對臭氧有中度相關及高度相關之因子，來作為日後建立模型的數據來源。

二、模型建立方法

在分析完所需的數據後，本研究使用不同的演算法來建立模型，例如：多元線性迴歸、線性迴歸、多項式迴歸、決策樹、類神經網路模型，以了解何種模型最適合本次研究，以下先設定本研究的準確度標準，再依序說明各種模型：

本研究定義準確度的衡量標準為

$$準確度 = \frac{誤差百分比在30\%以內的資料筆數}{全部的資料筆數}$$

（一）線性迴歸

線性迴歸之數學意義如同 $y = ax + b$ 的方程式，其中 y 和 x 為兩組變數、 a 為係數、b 為常數項，屬於變數一對一的函數。在研究中， y 為所預測值（臭氧濃度） ， x 為影響因子（ AMB_TEMP 等），係數 a 與常數項 b 則是經由機器學習所計算出來的。

（龍騰數學課本第二冊）

（二）多項式迴歸

多項式迴歸之數學意義如同 $y = a_n x^n + a_{n-1} x^{n-1} + \cdots + a_2 x^2 + a_1 x^1 + b$ 的方程式，其中 y 和 x 為兩組變數、 n 為 x 最高次、 a_n 為 x^n 的係數、 b 為常數項，屬於變數一對一的函數。與線性迴歸不同，多項式迴歸之圖形更貼近曲線。在研究中， y 為所預測值（臭氧濃度）， x 為影響因子（ AMB_TEMP 等 ），係數 a_n 到 a_1 與常數項 b 則是經由機器學習所計算出來的。

（龍騰數學課本第二冊）

（三）多元線性迴歸

多元線性迴歸與上述兩者變數一對一的函數不同，其數學意義為

$$y = a_1x_1 + a_2x_2 + \cdots + a_nx_n + b$$

其中 y 為變數、 n 代表有 n 個變數、 x_n 為第 n 個變數、 a_n 為 x_n 的係數、 b 為常數項，屬於變數多對一之函數。 y 為所預測值（臭氧濃度）， x_n 為影響因子（AMB_TEMP 等），係數 a_1 到 a_n 與常數項 b 則是經由機器學習所計算出來的。

（龍騰數學課本第二冊）

（四）多元線性迴歸反向淘汰法

反向淘汰法是藉由刪除變數一步一步檢視不同狀態下多元線性迴歸之準確度。本研究將六個變數一次淘汰一個對模型影響最小之變數，並觀察準確度之變化。

（五）決策樹

決策樹用於對眾多的數據進行分類，它使用樹狀結構來表示一系列的決策規則，用於對給定的數據進行分類或迴歸分析。

（李航，2022）

（六）類神經網路

類神經網路是一種模擬人類大腦神經元運作的計算模型，可被視為一個多層的非線性函數映射，其中每一層都是由多個線性函數或非線性函數所轉換而成。這些轉換通常由矩陣乘法和非線性函數所構成，其中矩陣的權重則是經由機器學習所計算出來的。

（Tariq Rashid，2018）

肆、研究結果

一、比較秋冬兩季臭氧濃度與其他變因的相關係數

表 4-1 單一影響因子與臭氧的相關係數

相關係數	AMB_TEMP	CH_4	CO	$NMHC$	NO_2	NO_x	RH	THC
	0.59	-0.32	-0.33	-0.47	-0.40	-0.42	-0.66	-0.60
皮爾森相關係數	中	低	低	低	低	低	中	中

本研究先比較一年四季臭氧濃度變化，發現秋冬兩季的臭氧濃度較高，因此研究者使用這兩季的資料做為模型的數據來源。臭氧濃度與各變因的相關係數如表 4-1，臭氧濃度與 AMB_TEMP 成正相關，而與 CH_4、CO、$NMHC$、NO_2、NO_x、RH、THC 成負相關，其中 CH_4、CO 的相關程度較低，因此在建立模型時，先刪除 CH_4、CO 這兩項因子，在單一因子影響臭氧濃度中， 也不特別探討 CH_4、CO 對臭氧的影響。 各種影響因子對臭氧的關係圖 ， 如圖 4-1 到圖 4-8：

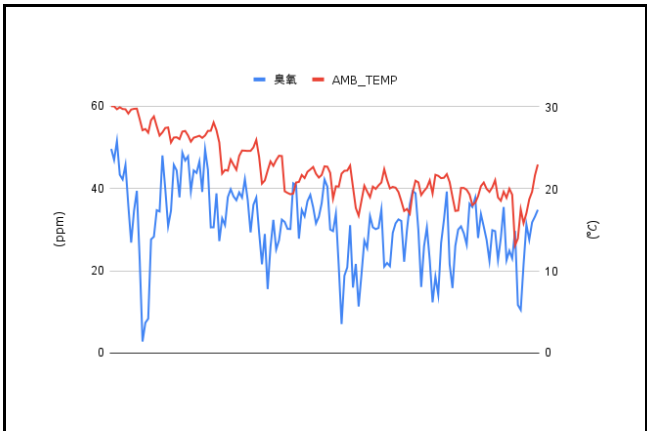

圖 4-1 AMB_TEMP 對臭氧的關係圖

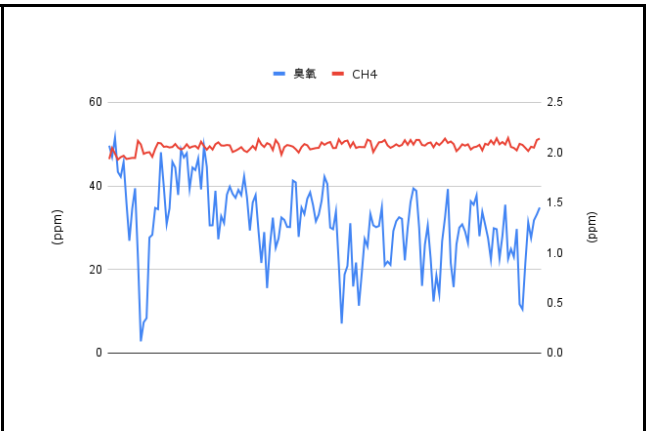

圖 4-2 CH_4 對臭氧的關係圖

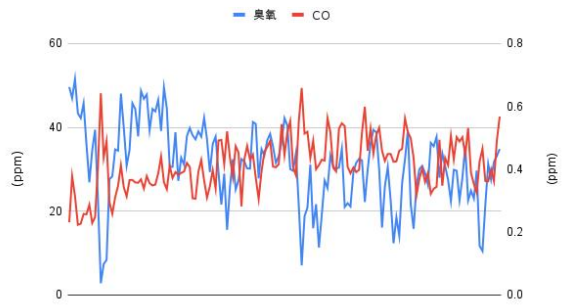

圖 4-3　CO 對臭氧的關係圖

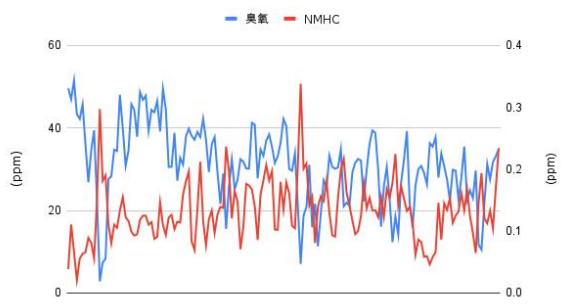

圖 4-4　$NMHC$ 對臭氧的關係圖

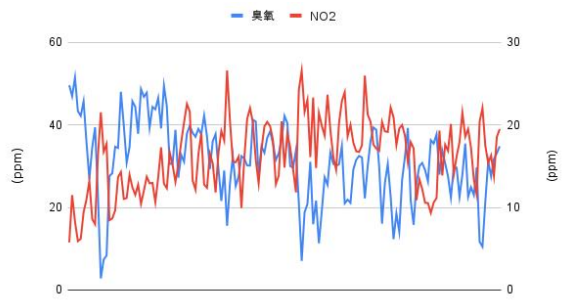

圖 4-5　NO_2 對臭氧的關係圖

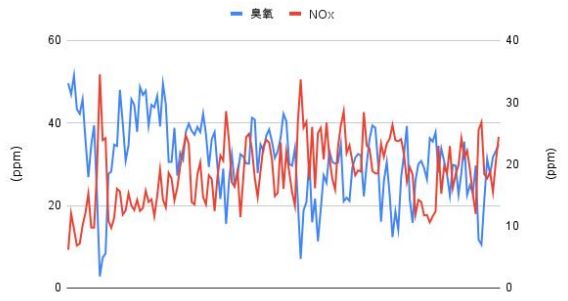

圖 4-6　NO_x 對臭氧的關係圖

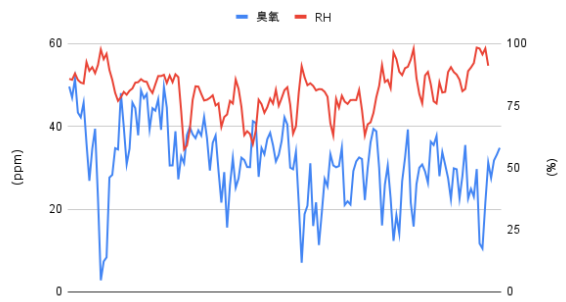

圖 4-7　RH 對臭氧的關係圖

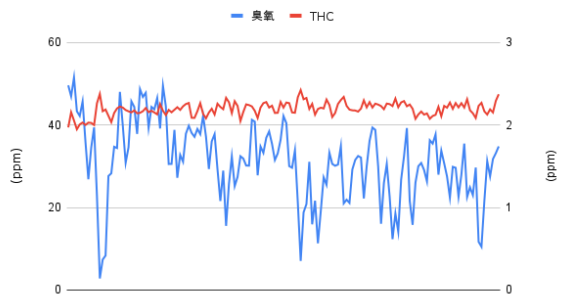

圖 4-8　THC 對臭氧的關係圖

二、觀察各預測模型之預測結果及其準確度

（一）線性迴歸

1. AMB_TEMP

使用 AMB_TEMP 與臭氧進行線性迴歸分析得出的方程式為

$$y = 1.30[AMB_TEMP] + 0.26$$

其準確度為 31.44 %

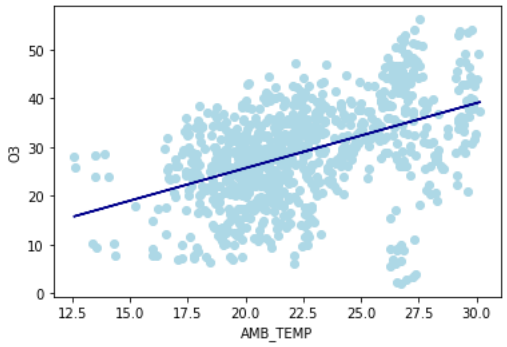

圖 4-9 AMB_TEMP與臭氧在訓練集的圖形

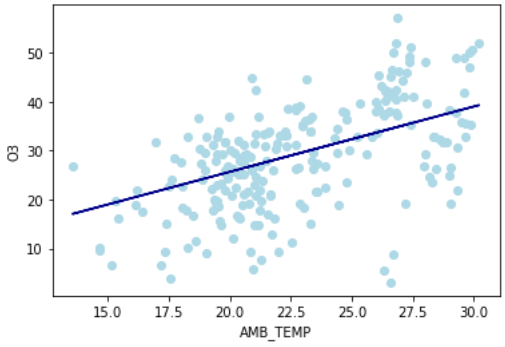

圖 4-10 AMB_TEMP與臭氧在驗證集的圖形

2. $NMHC$

使用 $NMHC$ 與臭氧進行線性迴歸分析得出的方程式為

$$y = -53.68[NMHC] + 38.01$$

其準確度為 18.12 %

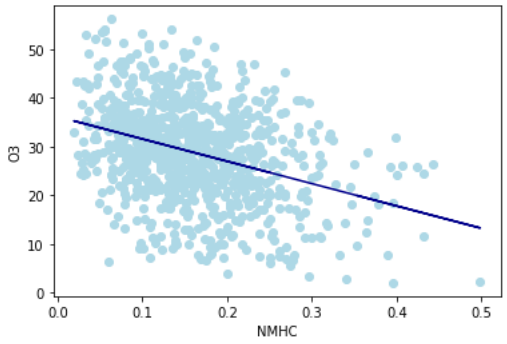

圖 4-11 $NMHC$ 與臭氧在訓練集的圖形

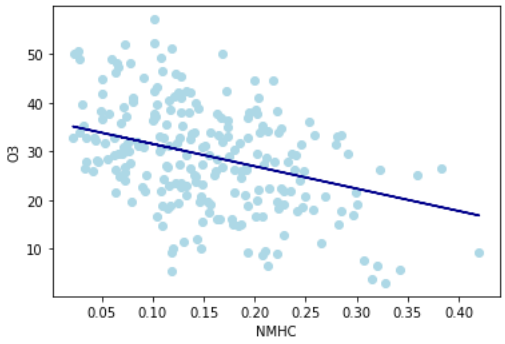

圖 4-12 $NMHC$ 與臭氧在驗證集的圖形

3. NO_2

使用 NO_2 與臭氧進行線性迴歸分析得出的方程式為

$$y = -0.90[NO_2] + 46.22$$

其準確度為 28.31 %

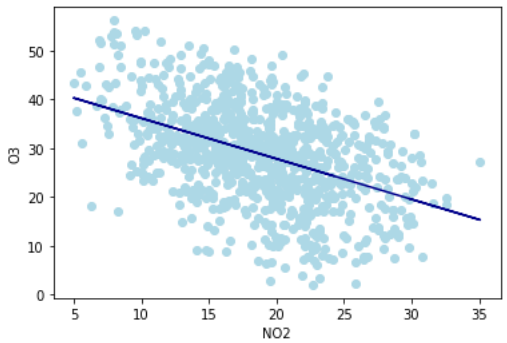

圖 4-13 NO_2 與臭氧在訓練集的圖形

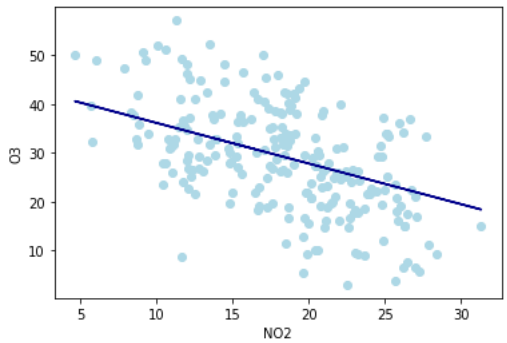

圖 4-14 NO_2 與臭氧在驗證集的圖形

4. NO_x

使用 NO_x 與臭氧進行線性迴歸分析得出的方程式為

$$y = -0.82[NO_x] + 47.10$$

其準確度為 38.91 %

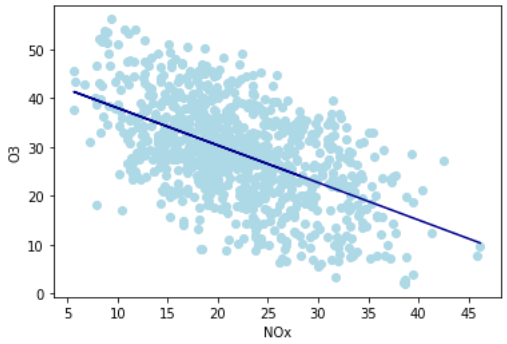

圖 4-15 NO_x 與臭氧在訓練集的圖形

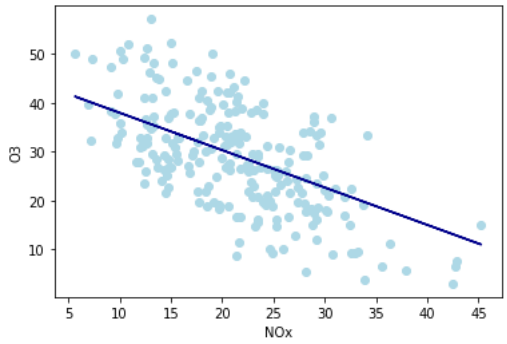

圖 4-16 NO_x 與臭氧在驗證集的圖形

5. RH

使用 RH 與臭氧進行線性迴歸分析得出的方程式為

$$y = -0.38[RH] + 59.20$$

其準確度為 12.43 %

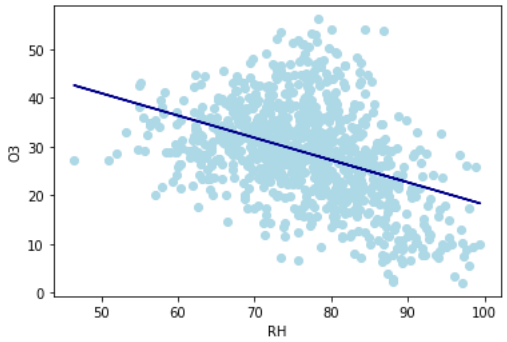

圖 4-17 RH 與臭氧在訓練集的圖形

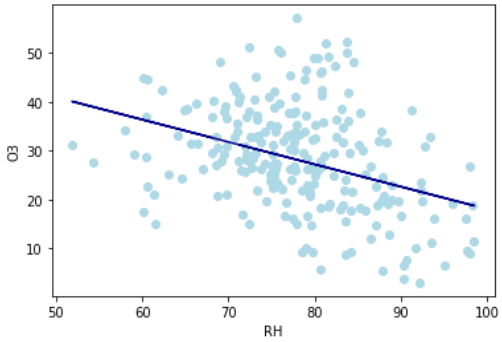

圖 4-18 RH 與臭氧在驗證集的圖形

6. THC

使用 THC 與臭氧進行線性迴歸分析得出的方程式為

$$y = -30.75[THC] + 98.76$$

其準確度為 12.15 %

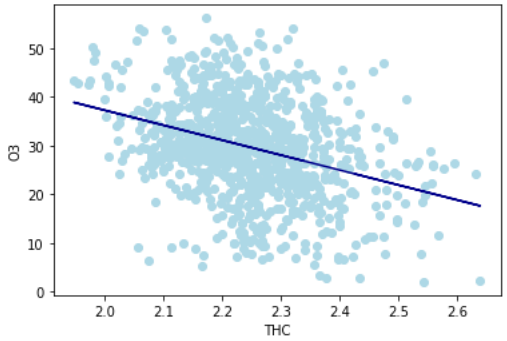

圖 4-19 THC 與臭氧在訓練集的圖形

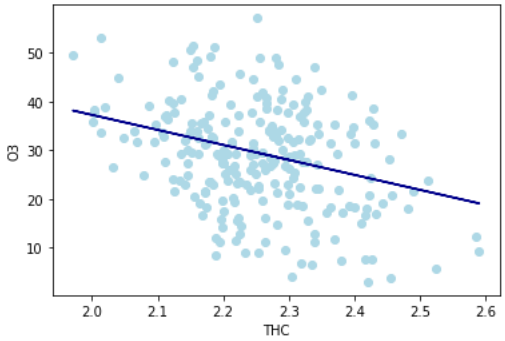

圖 4-20 THC 與臭氧在驗證集的圖形

（二）多項式迴歸

1. AMB_TEMP

使用 AMB_TEMP 與臭氧進行多項式迴歸分析得出的方程式為

$$y = -0.008[AMB_TEMP]^3 + 0.51[AMB_TEMP]^2 - 9.67[AMB_TEMP] + 77.51$$

其準確度為 25.47 %

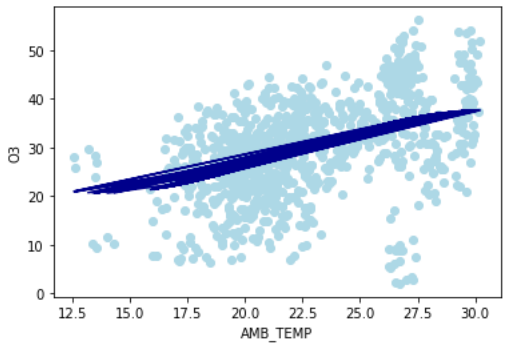

圖 4-21 AMB_TEMP與臭氧在訓練集的圖形

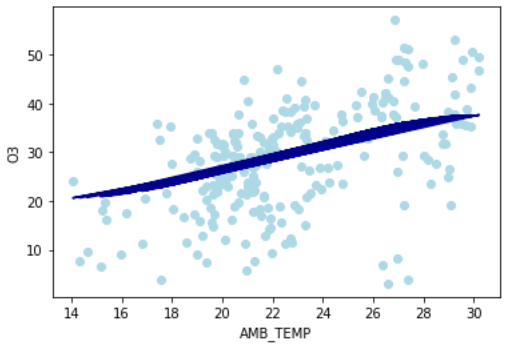

圖 4-22 AMB_TEMP與臭氧在驗證集的圖形

2. $NMHC$

使用 $NMHC$ 與臭氧進行多項式迴歸分析得出的方程式為

$$y = 48.86[NMHC]^3 + 6.82[NMHC]^2 - 62.54[NMHC] + 38.87$$

其準確度為 18.81 %

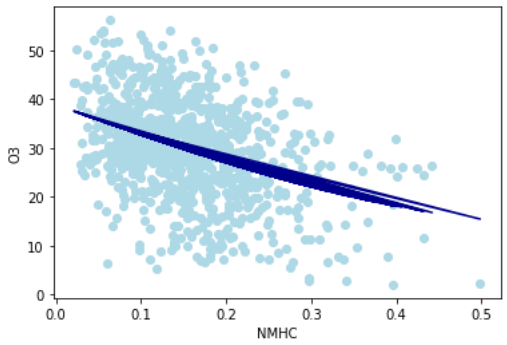

圖 4-23 $NMHC$ 與臭氧在訓練集的圖形

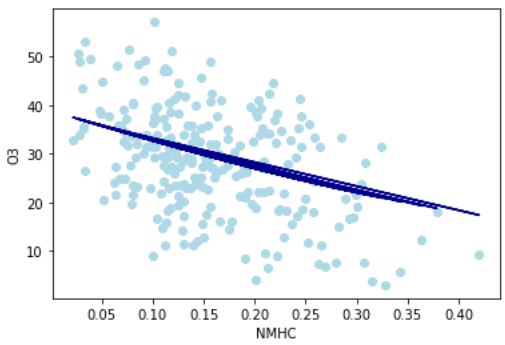

圖 4-24 $NMHC$ 與臭氧在驗證集的圖形

3. NO_2

使用 NO_2 與臭氧進行多項式迴歸分析得出的方程式為

$$y = 0.002[NO_2]^3 - 0.09[NO_2]^2 + 0.56[NO_2] + 39.42$$

其準確度為 25.67 %

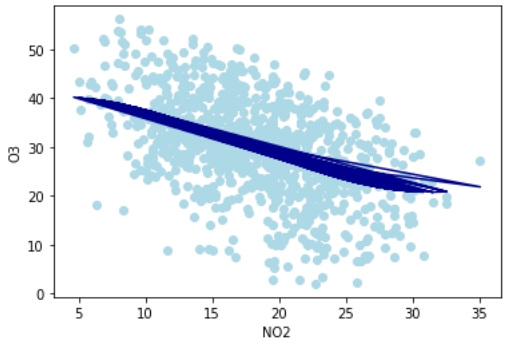	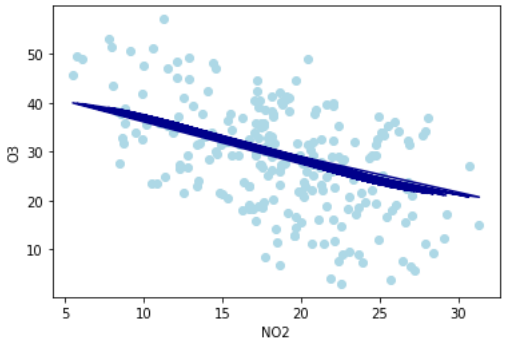
圖 4-25 NO_2 與臭氧在訓練集的圖形	圖 4-26 NO_2 與臭氧在驗證集的圖形

4. NO_x

使用 NO_x 與臭氧進行多項式迴歸分析得出的方程式為

$$y = -0.0003[NO_x]^3 - 0.02[NO_x]^2 - 0.41[NO_x] + 44.49$$

其準確度為 37.59 %

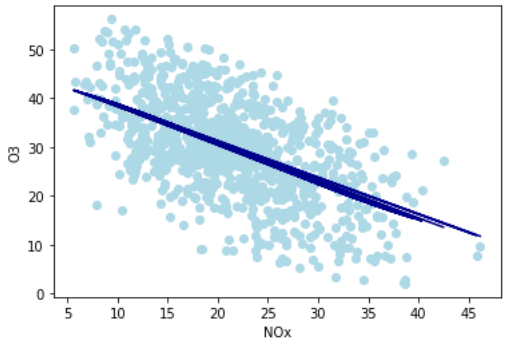	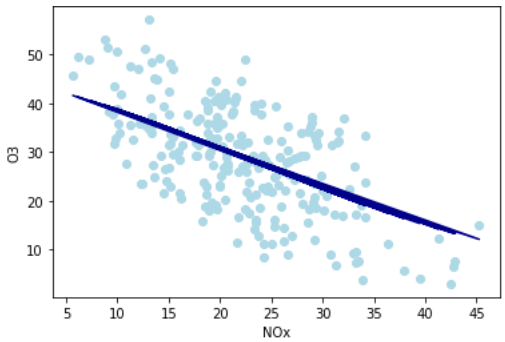
圖 4-27 NO_x 與臭氧在訓練集的圖形	圖 4-28 NO_x 與臭氧在驗證集的圖形

5. RH

使用 RH 與臭氧進行多項式迴歸分析得出的方程式為

$$y = -0.0004[RH]^3 - 0.007[RH]^2 - 3.56[RH] + 89.26$$

其準確度為 26.44 %

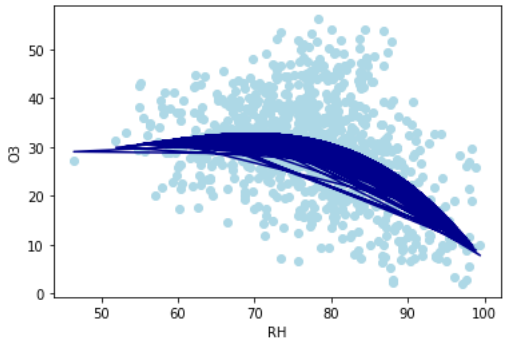

圖 4-29 RH 與臭氧在訓練集的圖形

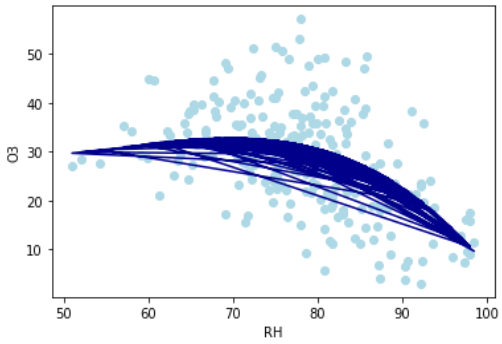

圖 4-30 RH 與臭氧在驗證集的圖形

6. THC

使用 THC 與臭氧進行多項式迴歸分析得出的方程式為

$$y = -49.12[THC]^3 + 341.41[THC]^2 - 819.36[THC] + 704.20$$

其準確度為 12.40 %

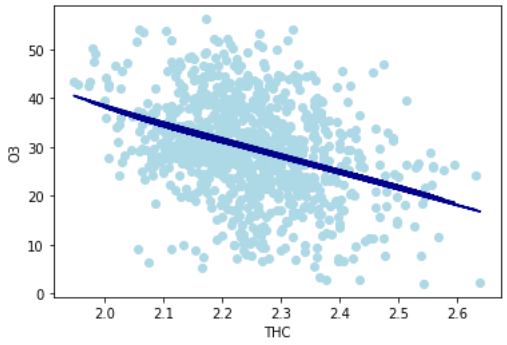

圖 4-31 THC 與臭氧在訓練集的圖形

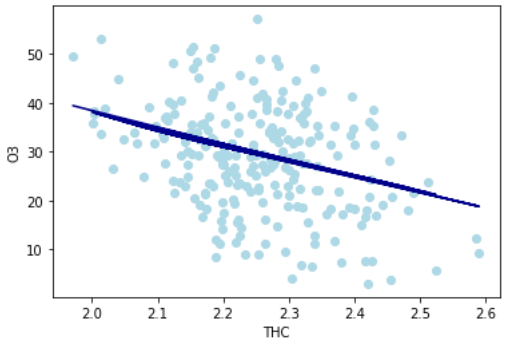

圖 4-32 THC 與臭氧在驗證集的圖形

（三）多元線性迴歸

使用 AMB_TEMP 、 $NMHC$ 、 NO_2 、 NO_x 、 RH 、 THC 六個參數與臭氧進行線性迴歸分析得出的方程式為：

$$y = 0.83[AMB_TEMP] - 0.40[NMHC] + 1.40[NO_2] - 1.76[NO_x] - 0.34[RH] + 3.38[THC] + 41.54$$

其準確度為 65.82 %

（四）多元線性迴歸反向淘汰法

每次從 AMB_TEMP、$NMHC$、NO_2、 NO_x 、 RH 、 THC 六個參數找出對準確率影響之變數進行刪減。

表 4-2 多元線性迴歸反向淘汰法

刪減變數	剩下之變數	準確值（%）	準確值增幅（%）
無	AMB_TEMP、$NMHC$、NO_2、NO_x、RH、THC	65.82%	0%
NO_2	AMB_TEMP、$NMHC$、NO_x、RH、THC	65.89%	0.07%
$NMHC$	AMB_TEMP、NO_x、RH、THC	65.74%	-0.15%
THC	AMB_TEMP、NO_x、RH	65.27%	-0.47%
AMB_TEMP	AMB_TEMP、NO_x	57.91%	-7.66%
RH	NO_x	38.91%	-19.00%

（五）決策樹

使用 AMB_TEMP、$NMHC$、 NO_2、NO_x、RH、THC 六個參數與臭氧進行決策樹。準確度為 64.15 %。

（六）類神經網路

使用 AMB_TEMP、$NMHC$、 NO_2、NO_x、RH、THC 六個參數與臭氧進行類神經網路，準確度為 69.15 %。

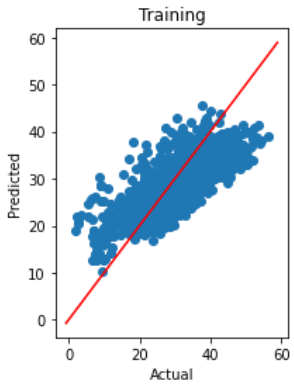

圖 4-33 類神經網路在訓練集的圖形

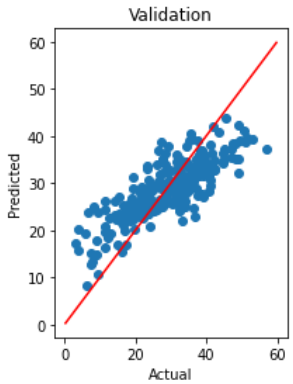

圖 4-34 類神經網路在驗證集的圖形

伍、討論

一、探討各預測模型之數學意義

（一）線性迴歸

線性迴歸是一種在統計學上用在以線性函數預測數值的方法。假設有一個自變量 x 以及一個因變量 y，此迴歸模型能表示成：

$$y = ax + b，\ a \text{ 為斜率，} \ b \text{ 為 } y \text{ 截距}$$

在 Python 中的 Linear Regression 函式是利用最小平方法來找出這條最佳的迴歸直線中的斜率以及 y 截距，此直線能最小化所有預測值與實際值差的平方，找出最佳的線性迴歸模型。

使用最小平方法時，會先取一條直線來慢慢逼近，並選擇預測值與實際值差的平方較小的線性模型做為下一條擬合線，直到找不到殘差平方更小的直線。而在找下一條擬合線時，可透過求解線性方程式而得到，圖 5-1 為線性迴歸的程式碼。

```
## 訓練與建構迴歸模型
regressor = LinearRegression()
regressor.fit(x_train, y_train)

## O3 = w_1*x+w_0

## 計算出截距值與係數值
w_0 = regressor.intercept_
w_1 = regressor.coef_

print('Interception : ', w_0)
print('Coeficient : ', w_1)

## 迴歸模型的準確度
score = regressor.score(x_test, y_test)
print('Score: ', score)
print('Accuracy: ' + str(score*100) + '%')
```

圖 5-1 線性迴歸程式碼

（二）多項式迴歸

多項式迴歸是一種基於多項式函數來建立預測模型的迴歸方法，原有的線性迴歸所導出的是一條直線，而多項式迴歸是以一次方程式為基礎，擴充自變量的高次方項，進而提高模型的複雜度，因此得出的模型為一條曲線。此迴歸模型能表示成：

$$y = a_n x^n + a_{n-1} x^{n-1} + \cdots + a_2 x^2 + a_1 x^1 + b$$

在 Python 中的 make pipeline 函式可找出多項式迴歸的模型，使用者可以自行調整次方數。次方數越高，雖然可以使圖形更接近訓練集數據，但並不代表準確度會高，因為可能會導致過度擬合的問題。同理，若本研究使訓練集中預測值與實際值差的平方極小化，並不能保證在驗證集中的準確度會高，圖 5-2 為多項式迴歸程式碼。

```
from sklearn.linear_model import LinearRegression
from sklearn.preprocessing import PolynomialFeatures
poly_reg = PolynomialFeatures(degree = 3) ## 可以替換最高次方
x_poly = poly_reg.fit_transform(x_train)
lin_reg_2 = LinearRegression().fit(x_poly, y_train)
lin_reg_2.coef_
## 使用訓練集資料來訓練(擬和)迴歸模型
regressor = make_pipeline(PolynomialFeatures(3), LinearRegression())    ## 可以替換最高次方
regressor.fit(x_train, y_train)

## 迴歸模型的準確度
score = regressor.score(x_test, y_test)
print('Score: ', score)
print('Accuracy: ' + str(score*100) + '%')
```

圖 5-2 多項式迴歸程式碼

（三）多元線性迴歸

多元線性迴歸是線性迴歸的擴展形式，使用多個自變量來預測應變量，本研究中使用六個自變量來建立迴歸模型。假設有六個自變量 (x_1、x_2、x_3、x_4、x_5、x_6) 與應變量 y，此迴歸模型能表示成：

$$y = a_1 x_1 + a_2 x_2 + a_3 x_3 + a_4 x_4 + a_5 x_5 + a_6 x_6 + b$$

在 Python 中也是使用 Linear Regression 函式藉由最小平方法來找出此迴歸線，也能最小化所有預測值與實際值差的平方，圖 5-3 為多元線性迴歸程式碼。

```
## 訓練與建構迴歸模型
regressor = LinearRegression()
regressor.fit(x_train, y_train)

## 計算出截距值與係數值
w_0 = regressor.intercept_
w_1 = regressor.coef_

print('Interception : ', w_0)
print('Coeficient : ', w_1)

## 迴歸模型的準確度
score = regressor.score(x_test, y_test)
# print("MAE = {:.3f}".format(mean_absolute_error(y_test, regressor.predict(x_test))))
print('Score: ', score)
print('Accuracy: ' + str(score*100) + '%')
```

圖 5-3 多元線性迴歸程式碼

（四）決策樹

決策樹在數學上可視為一種條件機率的模型，決策樹為由 n 個節點與 $n-1$ 條邊組成的有向無環圖，因此為一個樹狀結構。每個節點代表逕行分類的標準，而每條邊代表測試結果的分支，從根節點沿著決策樹進行選擇，直到達到葉節點，即為最終預測結果。

決策樹使用遞迴分割與分治法等技術，將狀態藉由分類來切分成很多子集，以進行數據預測。圖 5-4 為決策樹的程式碼。

```
param_grid = {'max_depth': [3, 4, 5, 6, 7, 8, 9, 10, None]}
tree_model = GridSearchCV(DecisionTreeRegressor(random_state=0),
                          cv = 5,
                          scoring = 'neg_mean_squared_error',
                          param_grid = param_grid)
tree_model.fit(x_train, y_train)
```

圖 5-4 決策樹程式碼

（五）類神經網路

類神經網路模型是一種模擬人類神經元的計算系統，利用機器學習，學習樣本間的關係，再用其非線性映射能力和無模型估計的特質，有效解決問題。類神經網路不須事先在輸出輸入參數間建立數學模型，因此在無法確立輸出輸入參數間的關係時，此方法較線性迴歸方法

佳。此模型可用來解決複雜的非線性問題，其基本運算有矩陣運算、向量運算、非線性函數、微分和積分等。圖 5-5 為建構類神經網路模型的程式碼。

```
# build the model!
model = Sequential()
model.add(Dense(50, input_shape=(x_train.shape[1],), activation='linear'))
model.add(Dense(20, activation='linear'))
model.add(Dense(20, activation='relu'))
model.add(Dense(1, activation='linear')) # output node
model.summary() # see what your model looks like

# compile the model
model.compile(optimizer='rmsprop', loss='mse', metrics=['mae'])

# early stopping callback
es = EarlyStopping(monitor='val_loss',
                   mode='min',
                   patience=50,
                   restore_best_weights = True)

# fit the model!
# attach it to a new variable called 'history' in case
# to look at the learning curves
history = model.fit(x_train, y_train, validation_data = (x_test, y_test),
                    callbacks = [es],
                    epochs = 100,
                    batch_size = 8,
                    verbose = 1)
```

圖 5-5 建構類神經網路模型的程式碼

二、比較不同建立模型方式的準確度以及其可行性

（一）線性迴歸

表 5-1 使用線性迴歸時單一影響因子預測臭氧的準確度

準確度(%)	AMB_TEMP	$NMHC$	NO_2	NO_x	RH	THC
	25.47	18.81	28.31	38.91	12.43	12.15
相關係數	0.59	-0.47	-0.40	-0.42	-0.66	-0.60

在使用不同因子對臭氧建立線性迴歸模型，其準確度由高到低依序為：NO_x、AMB_TEMP、NO_2、$NMHC$、RH、THC。當中以 AMB_TEMP、NO_2 與 NO_x 預測臭氧的線性模型時，準確度較高。

（二）多項式迴歸

表 5-2 使用多項式迴歸時單一影響因子預測臭氧的準確度

準確度(%)	AMB_TEMP	$NMHC$	NO_2	NO_x	RH	THC
	31.44	18.12	25.67	37.59	26.44	12.40

在使用不同因子對臭氧建立多項式迴歸模型，其準確度由高到低依序為：NO_x、AMB_TEMP、NO_2、$NMHC$、RH、THC。當中以 AMB_TEMP、NO_2、NO_x 與 RH 預測臭氧的線性模型時，準確度較高。

表 5-3 線性迴歸與多項式迴歸準確度差值比較

準確度差值(%)	AMB_TEMP	$NMHC$	NO_2	NO_x	RH	THC
	5.97	-0.69	-2.64	-1.32	14.01	0.25

線性迴歸模型與多項式迴歸模型的準確度差值比較如表 5-3 所示，得知增加次方項普遍對準確度並無太大的影響，然而，多項式迴歸使 AMB_TEMP 與 RH 的準確度明顯提高，AMB_TEMP 小幅提高，因此推測 RH 與臭氧為指數關係，其餘因子與臭氧成線性關係。

（三）多元線性迴歸

多元線性迴歸的準確度達到 65.82% ，相比於線性迴歸所測得的準確度高出了不少，達到兩倍之多。在使用線性迴歸考慮到的因子只有一個，而多元線性迴歸所考量到的因子有六個，故本研究可以知道影響臭氧的變因有很多，單單考慮一種變因的準確度有所侷限。

（四）決策樹

本研究使用 Python 的 tree model 套件建構決策數，由於決策樹是一種條件機率的模型，透過將資料分類之方式，相比於迴歸直線可以一次性處理有著大量變因的資料，且在分析上不易受到極端值干擾，使其準確度達到 64.15 %。

（五）類神經網路

本研究使用 Python 的 Keras 套件建構神經網路，神經網路為模擬人腦內神經的演算法，是一種結合線性及非線性的函數。在經過一連串的模型測試與調整後，本研究最終採用了 4 層的類神經網路：輸入層包含 AMB_TEMP 、 $NMHC$ 、 NO_2 、 NO_x 、 RH 、 THC 共六個參數，中間有 3 個隱藏層，分別有 50、20 及 20 個神經元，最後輸出層計算出 O_3 濃度，如圖 5-6 所示。由圖 5-7 可得知，使用這個模型的類神經網路共有 1811 個參數，而多元線性迴歸只有 7 個參數，遠比多元線性迴歸的參數量多，並且它是個非線性模型，因此可以更能接近符合的預測模型。

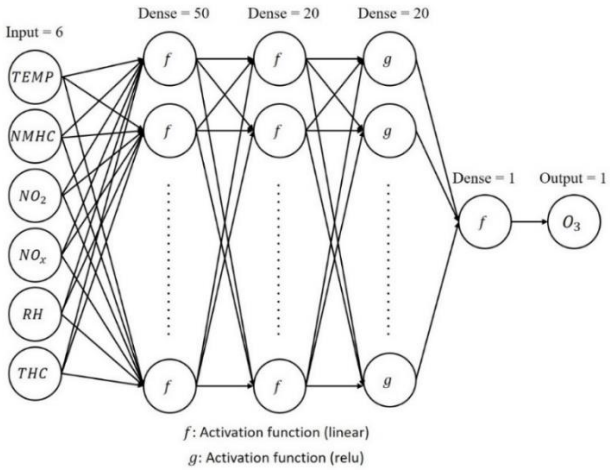

圖 5-6 類神經網路模型及其參數個數

```
Model: "sequential"
_________________________________________________________________
 Layer (type)                Output Shape              Param #
=================================================================
 dense (Dense)               (None, 50)                350

 dense_1 (Dense)             (None, 20)                1020

 dense_2 (Dense)             (None, 20)                420

 dense_3 (Dense)             (None, 1)                 21

=================================================================
Total params: 1,811
Trainable params: 1,811
Non-trainable params: 0
```

圖 5-7 類神經網路模型及其參數個數

本研究先將數據切分成 80% 的訓練集以及 20% 的驗證集，將訓練集拿去讓模型訓練。由圖 5-8 可知，經過大約 80 個回合後，損失函數就不再下降。藍色線為訓練集中預測值與實際值的誤差，而黃色線為驗證集中預測值與實際值的誤差。

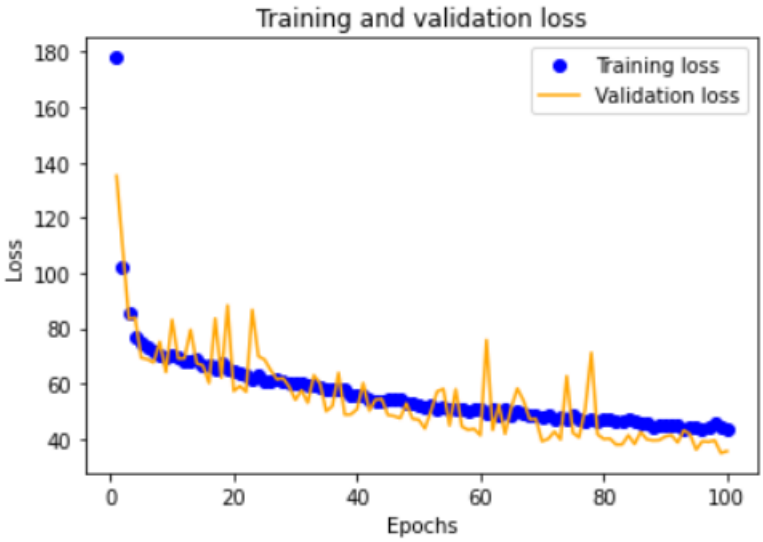

圖 5-8 損失函數變化

圖 5-9 和圖 5-10 為類神經網路模型在訓練集與驗證集中臭氧測量值與預測值的圖形，最後由驗證集計算出類神經網路的準確度高達 69.15 %。

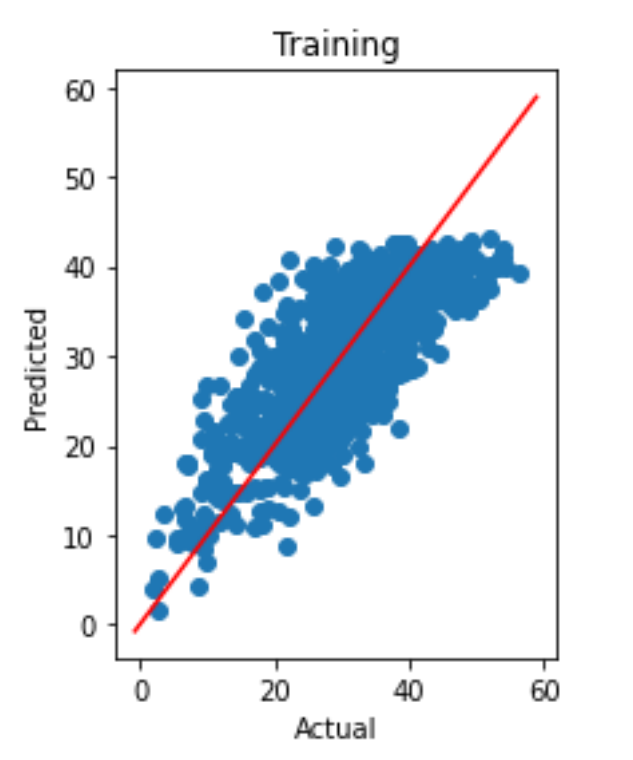

圖 5-9 類神經網路在訓練集的圖形

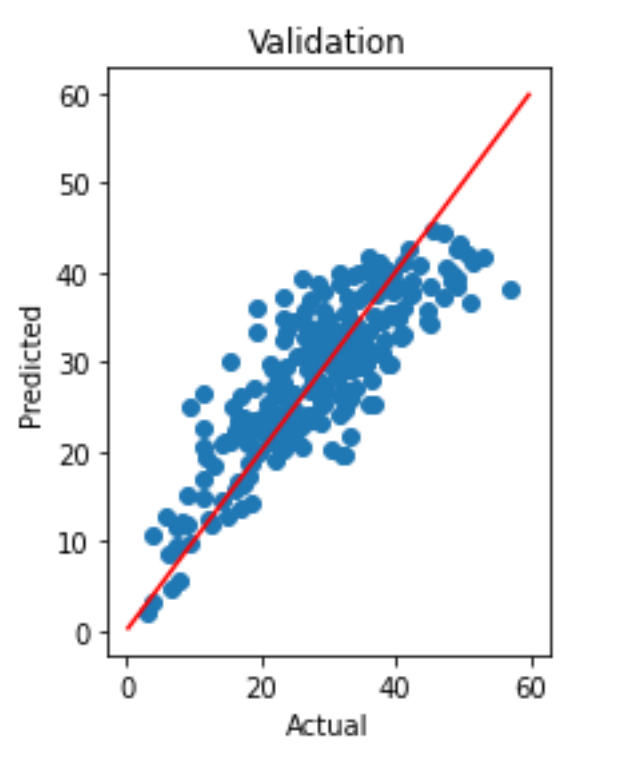

圖 5-10 類神經網路在驗證集的圖形

三、比較不同研究之結果

為了解此次研究與其他類似研究有何不同，研究者分析林佳暄（2022）的研究，其利用 NO_2 、紫外線、風速三種變因結合類神經網路預測臭氧濃度，下表 5-4 為此研究與林佳暄研究之比較。

表 5-4 與林佳暄（2022）研究之比較

	影響因子	模型	準確度
林佳暄（2022）研究	NO_2 、紫外線、風速	類神經網路	51%
此次研究	AMB_TEMP 、 $NMHC$ 、 NO_2 、 NO_x 、 RH 、 THC	多元線性迴歸	65.89%（反向）
		決策樹	64.15 %
		類神經網路	69.15%

陸、研究結論

一、比較秋冬兩季臭氧濃度與其他變因的相關係數

（一）在影響因子中與臭氧濃度成中度相關者有 AMB_TEMP、RH、THC；成低度相關者有 CH_4、CO、$NMHC$、NO_2、NO_x。

（二）透過用各項變因對臭氧做線性迴歸得知，相關係數與準確度並不成正相關。

（三）透過與林佳暄（2022）研究比較後，得知透過 AMB_TEMP、$NMHC$、NO_2、NO_x 、RH 、 THC 在類神經網路的預測下較 NO_2、紫外線、風速的準確度來的高。

二、探討各預測模型之數學意義

（一）線性迴歸

線性迴歸是利用最小平方法來找出這條迴歸直線，先取一條直線來慢慢逼近，並選擇預測值與實際值差的平方較小的線性模型做為下一條擬合線，直到找不到殘差平方更小的直線，這條迴歸直線能最小化所有預測值與實際值差的平方。

（二）多項式迴歸

多項式迴歸是以一次方程式為基礎，擴充自變量的高次方項，進而提高模型的複雜度，因此得出的模型為一條曲線。

（三）多元線性迴歸

多元線性迴歸是線性迴歸的擴展形式，也是藉由最小平方法來找出此迴歸線，能最小化所有預測值與實際值差的平方。

（四）決策樹

決策樹使用遞迴分割與分治法等技術，將狀態藉由分類來切分成很多子集，以進行數據預測。

（五）類神經網路

類神經網路利用自動學習，學習樣本間的關係，此方法可用來解決複雜的非線性問題，其基本運算有矩陣運算、向量運算、非線性函數、微分和積分等。

三、比較不同建立模型方式的準確度

本研究比較各模型的準確度、線性或非線性及各模型的影響因子數量。由表 6-1 可知線性函數準確度高於非線性函數；多影響因子的函數準確度高於單因子函數。

表 6-1 不同建立模型方式比較表（備註：線性與多項式迴歸均以 NO_x 為代表）

	線性迴歸	多項式迴歸	多元線性迴歸	決策樹	類神經網路
準確度	38.91%	37.59%	65.89%（反向）	64.15 %	69.15%
線性/非線性	線性	線性	線性	非線性	線性/非線性
影響因子	單個	單個	多個	多個	多個

（一）在此次研究中各變因對臭氧進行模型預測結果可知，非線性函數的準確度最低、線性函數其次、兩者皆有的類神經網路最高。

（二）透過表 6-1 的結果得知，單個因子的準確度遠不如多個因子。

（三）透過與林佳暄（2022）研究進行比較後得知使用 AMB_TEMP 、 $NMHC$ 、 NO_2 、 NO_x 、 RH 、 THC 變因預測臭氧模型，準確度能提升 18.15%。

四、未來展望

臭氧的變因太多以現階段所使用到的方法無法預測到 70% 以上，希望未來能透過以下方式進行更深入的探討：

（一）研究更多不同演算法的模型，如卷積神經網路，來增加臭氧的準確度，與此同時，可以透過比較不同演算法以了解臭氧預測背後的數學意義。

（二）探討更多不同的因子，了解因子與因子間在大自然中的關係，並納入影響力高的因子，以提升模型的準確度。

柒、參考資料

一、網站資料

(一) 環保署空氣品質資訊網。 https://iaq.epa.gov.tw/indoorair/Default.aspx

(二) 環保署空氣品質資訊網，臺灣空品時空特徵。

https://airtw.epa.gov.tw/cht/Encyclopedia/pedia08/pedia4_11.aspx

(三) 環保署空氣品質資訊網，空氣品質標準法規。

https://airtw.epa.gov.tw/cht/Information/Standard/Rules.aspx

二、文獻資料

(一) 柳中明、盧開新（1991）。箱型光化模式之初步發展驗證與應用。

(二) 蔡詠安（2001）。氣象條件與臭氧事件日相關性之探討：以高高屏地區為例。

(三) 盧昱璇、郭怡彤(2015)。穹頂之下，高雄市。

(四) 龍騰數學課本第二冊。

(五) 李航(2022)。機器學習聖經：最完整的統計學習方法。

(六) Tariq Rashid(2018)。類神經網路實戰：使用 Python。

(七) 林佳暄(2022)。氧出神經-以類神經網路預測臭氧濃度。